家电财报问答知识库

作业三 / 方向 A / 2025 年报 / 检索阶段真实结果

研究范围

选取美的、格力、海尔、海信家电、苏泊尔、九阳、新宝、小熊、
海信视像和长虹美菱十家公司。巨潮资讯完整年报共 2,366 页，
抽取 6,489 个证据块；保留下载地址、文件校验值和 PDF 页码。

实现方法

正文切块 1,400 字符、重叠 200 字符；识别表格按行列保存。
BM25 与 192 维 LSA 统计语义向量通过 RRF 融合，跨公司逐家检索。
基础指标优先检索主要会计数据章节；规则抽取数值并标注证据。
当前不调用大模型；解释类问题展示证据，证据不足不强行生成答案。

实际测试

10 道题、3 种检索模式。混合检索参考公司页覆盖：18/19。
混合检索规则答案 8/10 通过参考值核对（含 1 道合理拒答）。
两道跨公司题均完成；现金流量题、口径辨析题未回答，均计失败。
题目较少且偏重数值查询，不能外推为通用问答正确率。

发现与失败

直接检索易混入分业务和季度表，章节路由改善了基础指标定位。
九阳现金流量行名被数值列打断：原表有证据，但规则未解析出答案。
美的收入口径辨析未找到指定参考页，也超出当前规则解释能力。
未来年度问题明确拒答；同页引用可打开 PDF 核验原始表头及单位。

结论与边界

财报事实查询、原文溯源及跨公司资料汇集适合采用知识库检索。
规则回答可覆盖部分标准数值题，但表格布局与复杂解释仍是短板。
LSA 为统计语义向量，不是预训练 embedding；三路测试均叠加章节
路由，当前小样本不足以证明混合检索优于单路。后续可接入生成模型，
增加文字理解题与未见题，再检查答案、引用及计算的一致性。